

RAPPORT QUALITÉ DES DONNÉES

Data Profiling & Data Cleaning

Rapport complet du processus de profilage et de nettoyage des données appliqué aux tables Students, Courses et

Teachers avant la modélisation Power BI. Ce document présente les problèmes identifiés, les transformations appliquées et les enrichissements réalisés pour garantir la fiabilité des analyses et des tableaux de bord.

Objectifs du Profilage

Avant toute analyse ou création de tableau de bord, un profilage complet a été réalisé pour évaluer la qualité des données brutes et identifier les anomalies à corriger.



Valeurs manquantes

Identifier les champs vides ou nuls dans chaque table et évaluer leur impact sur les analyses.



Incohérences de types

Détecter les colonnes numériques importées en texte et les formats de date incorrects.



Doublons

Repérer et éliminer les lignes dupliquées pour garantir l'unicité des identifiants.



Valeurs aberrantes

Analyser les outliers dans les champs numériques pour détecter d'éventuelles anomalies.



Enrichissement

Identifier les indicateurs calculés manquants nécessaires aux analyses avancées.

Analyse — Table Students

Vue d'ensemble

124 enregistrements

~117-120 étudiants uniques

Qualité globale : Quelques anomalies détectées nécessitant correction avant analyse.

Problèmes identifiés

Champ	Problème	Détail
average_grade	Valeurs manquantes	2% (chaînes vides)
average_grade	Type incorrect	Text (ABC) → Decimal
absences_count	Valeurs manquantes	3 valeurs nulles
ID étudiant	Doublons	124 lignes, ~117 uniques



Aucun nombre négatif dans absences_count (Min = 0, Max = 40) — pas d'outliers détectés.


Analyse — Table Courses

Vue d'ensemble

500 enregistrements

Qualité globale : Taux de valeurs manquantes modéré sur plusieurs colonnes critiques.

Valeursmanquantes par champ



Champ	Problème	Détail
grade	Type incorrect	Text (ABC) → Decimal
completed_hours	Outliers	Aucun (Min=13, Max=60)



Les outliers des notes seront contrôlés après conversion du type numérique.

Analyse — Table Teachers

Vue d'ensemble

20 enseignants

Qualité globale : Table la plus propre
— un seul champ à corriger.

Problèmes identifiés

Champ	Problème	Détail
performance_rating	Valeur manquante	1 valeur (5%)
performance_rating	Type incorrect	Text (ABC) → Decimal




Aucun doublon détecté.



hire_date correctement importée au

format Date.

Problèmes Identifiés – Vue Globale



Ces quatre catégories de problèmes ont guidé l'ensemble des transformations appliquées lors de la phase de nettoyage. La correction des types de données et la gestion des valeurs manquantes constituent les priorités principales avant toute modélisation analytique.

Gestion des Valeurs Manquantes

Une stratégie différenciée a été appliquée selon la nature de chaque champ : médiane pour les variables numériques continues, valeur par défaut pour les catégories.

Colonne	Action appliquée	Remplacement	Justification
average_grade	médiane	Remplacement par la médiane	Variable numérique continue
grade	Remplacement	par la médiane	Variable numérique continue
performance_rating	Remplacement	par "Inconnu"	Variable numérique continue
pass_fail	Remplacement	par la médiane	Variable catégorielle
completed_hours	Remplacement	par la médiane	Variable numérique continue
absences_count			Variable numérique continue

Standardisation & Correction des Types

Standardisation textuelle

- Suppression des espaces superflus (Trim)
- Suppression des caractères invisibles (Clean)
- Uniformisation de la casse (Capitalize Each Word)
- Harmonisation du genre → valeur unique F

Correction des types de données

Colonne	Ancien type	Nouveau type
average_grade	Text (ABC)	Decimal Number
grade	Text (ABC)	Decimal Number
performance_rating	Text (ABC)	Decimal Number



Suppression des doublons dans la table
Students – conservation d'un identifiant unique
par étudiant.

Enrichissement des Données

De nouvelles colonnes calculées ont été créées pour enrichir le modèle et permettre des analyses avancées dans les tableaux de bord Power BI.



Âge Élève

Calculé à partir de la date de naissance de chaque étudiant.



Année d'inscription

Extraction de l'année depuis le champ `enrollment_date`.



Ancienneté Enseignant

Nombre d'années de service calculé depuis `hire_date`.



Taux de réalisation

Formule : $(\text{completed_hours} / \text{planned_hours}) \times 100$



Statut Passage

Réussi si note ≥ 10 , sinon Échec.

RÉSULTAT FINAL

Données Prêtes pour la Modélisation

Après l'ensemble des opérations de nettoyage et d'enrichissement, le jeu de données est maintenant fiable, cohérent et prêt pour la création des tableaux de bord Power BI.



Valeurs manquantes

Toutes traitées par médiane ou valeur par défaut



Types corrigés

3 colonnes converties en Decimal Number



Doublons supprimés

Identifiants étudiants uniques garantis



Textes standardisés

Trim, Clean, Capitalize appliqués



Indicateurs ajoutés

5 nouvelles colonnes calculées créées



✓ Les données sont désormais prêtes pour la modélisation Power BI : KPIs, graphiques et analyses peuvent être développés sur une base fiable et cohérente.